

Supposons un générateur de variables aléatoires iid uniformément distribuées sur  $[0 ; 1]$ ,  
Comment utiliser ces variables uniformes pour générer des variables aléatoires de distributions différentes ?

THE  
NORMAL  
LAW OF ERROR  
STANDS OUT IN THE  
EXPERIENCE OF MANKIND  
AS ONE OF THE BROADEST  
GENERALIZATIONS OF NATURAL  
PHILOSOPHY ? IT SERVES AS THE  
GUIDING INSTRUMENT IN RESEARCHES  
IN THE PHYSICAL AND SOCIAL SCIENCES AND  
IN MEDICINE AGRICULTURE AND ENGINEERING ?  
IT IS AN INDISPENSABLE TOOL FOR THE ANALYSIS AND THE  
INTERPRETATION OF THE BASIC DATA OBTAINED BY OBSERVATION AND EXPERIMENT  
William Youden (1962)

# Sommaire.

## 1 Méthode d'inversion

- Applications

## 2 Simulation de lois à densité par la méthode du rejet

## 3 Cas particulier : la loi normale

- Méthode inverse
- Théorème Central Limite
- Méthode de Box et Muller
- Méthode du rejet

## 4 Cas particulier des lois discrètes

# Simulation par la méthode d'inversion

Soit  $X$  est une variable alatoire avec une distribution uniforme dans  $[0, 1]$ ,  $F(x)$  sa fonction de répartition :

$$F(x) := P(X \leq x).$$

## Rappels :

- $F$  est croissante, continue à droite et limitée à gauche en tout point de  $\mathbb{R}$ .
- L'ensemble de ses discontinuités est au plus dénombrable.
- $F$  a pour limite 0 en  $-\infty$  et 1 en  $+\infty$ .

Dans le cas particulier où  $F$  est continue et strictement croissante sur tout  $\mathbb{R}$ , elle réalise une bijection de  $\mathbb{R}$  sur  $]0, 1[$  et admet donc une inverse

$$F^{-1} : ]0, 1[ \rightarrow \mathbb{R}$$

Si  $U$  est une variable aléatoire de loi uniforme sur  $]0, 1[$ , alors  $Y := F^{-1}(U)$  a même loi que  $X$ .

**Preuve** : calcul de la fonction de répartition de  $Y$  :

$$\forall x \in \mathbb{R}, P(Y \leq x) = P(F^{-1}(U) \leq x) = P(U \leq F(x)) = F(x).$$

Dans cette suite d'égalités, la deuxième repose sur la croissance de  $F$  et de  $F^{-1}$  qui légitime l'équivalence  $F^{-1}(U) \leq x \iff U \leq F(x)$ . La dernière égalité est due au calcul de la fonction de répartition de la loi uniforme sur  $]0, 1[$  (qui coïncide sur  $[0, 1]$  avec l'identité) et au fait que  $F(x) \in [0, 1]$ .

# Simulation par la méthode d'inversion

## Définition

La fonction inverse  $x = F^{-1}(y)$  est définie pour toute valeur de  $y$ ,  $y \in ]0, 1[$  telle que  $F^{-1}(y)$  soit la plus petite valeur de  $x$  satisfaisant  $F(x) \geq y$ . C'est-à-dire :

$$\forall y \in ]0, 1[ \quad F^{-1}(y) = \inf\{x \in \mathbb{R}; F_X(x) \geq y\}.$$

## ● Proposition

Si  $U$  est une v.a.r. de loi uniforme sur  $]0, 1[$  et  $X$  une v. a. r. de fonction de répartition  $F$  alors  $F^{-1}(U)$  a la même loi que  $X$ , c'est-à-dire admet  $F$  pour fonction de répartition.

## Pratiquement

Pour obtenir la distribution  $x$  d'une variable aléatoire  $X$ , on génère une suite de valeurs  $u$  de la variable aléatoire  $U$  distribuées sur  $[0, 1]$ , on calcule  $x = F^{-1}(u)$ .

# Lois uniformes

on dispose d'un générateur de nombres aléatoires dans l'intervalle  $[0, 1]$ .

- Distribution uniforme sur  $[a, b] : \mathcal{U}([a, b])$

Une variable aléatoire  $X$  suit une loi **rectangulaire** (loi uniforme sur un segment  $[a, b]$ ) si étant donné 2 nombres  $a$  et  $b$ , sa densité de probabilité est :

$$\begin{cases} f(x) = \frac{1}{b-a} & \text{si } a \leq x \leq b \\ f(x) = 0 & \text{si } x < a \text{ ou } x > b \end{cases} \cdot \quad \text{où } f(x) = \frac{1}{b-a} \mathbf{1}_{[a,b]}(x)$$

$$F \text{ fonction de répartition } \begin{cases} F(x) = 0 & \text{si } x \leq a \\ F(x) = \frac{x-a}{b-a} & \text{si } x \in [a, b[ \\ F(x) = 1 & \text{si } x \in [b, \infty[ \end{cases}$$

On peut générer une suite de telles variables à partir d'une suite de variables ayant une loi continue uniforme par la combinaison d'une homothétie de rapport  $(b - a)$  et d'une translation d'amplitude  $a$  :

$$\mathbf{F}^{-1}(\mathbf{u}) = \mathbf{y} = (\mathbf{b} - \mathbf{a})\mathbf{u} + \mathbf{a}.$$

Cette suite de nombres représentera une réalisation d'une suite de variables aléatoires  $X_1, X_2, X_3, \dots, X_N$  indépendantes et de loi uniforme sur  $[a, b]$ .

# Loi exponentielle

- Distribution exponentielle :  $\mathcal{E}(x)$ ,

Une variable aléatoire  $X$  suit une loi **exponentielle** de paramètre  $\lambda$  ( $\lambda > 0$ ) si sa densité de probabilité est :

$$f(x) = \lambda e^{-\lambda x} \mathbf{1}_{\{x>0\}}(x).$$

Sa fonction de répartition est

$$F(x) = 1 - e^{-\lambda x} \mathbf{1}_{\{x>0\}}(x) \quad [E(X) = \frac{1}{\lambda}, V(X) = \frac{1}{\lambda^2}].$$

On peut générer une suite de telles variables à partir d'une suite de variables ayant une loi continue uniforme sur  $[0, 1]$  par la résolution de l'équation :

$$\int_0^{y_i} \lambda e^{-\lambda t} dt = u.$$

Soit si  $u$  est une variable obtenue à partir d'une variable aléatoire de loi uniforme, on obtient donc une variable  $y$  de loi exponentielle par :

$$F^{-1}(u) = y = -\frac{1}{\lambda} \ln(1 - u).$$

On peut remplacer  $1 - u$  par  $u$  puisqu'ils suivent la même distribution et générer le nombre  $y = -\frac{1}{\lambda} \ln u$ .

# Loi de Weibull

- Distribution de Weibull :  $\mathcal{W}(\alpha, \beta)$ ,

Une variable aléatoire  $X$  suit une loi de **Weibull** de paramètre  $\alpha, \beta$  ( $\alpha > 0 \beta > 0$ ) si sa densité de probabilité est :

$$f(\mathbf{x}|\alpha; \beta) = \alpha \beta \mathbf{x}^{\alpha-1} \mathbf{e}^{-\beta \mathbf{x}^\alpha} \mathbf{1}_{\mathbb{R}^+}(\mathbf{x}).$$

Sa fonction de répartition :

$$\alpha > 0 \beta > 0, \quad F(x) = 1 - e^{-\beta x^\alpha} \mathbf{1}_{\mathbb{R}^+}(x).$$

Soit si  $u$  est une variable obtenue à partir d'une variable aléatoire de loi uniforme, on obtient donc une variable  $y$  de loi de Weibull par :

$$\mathbf{F}^{-1}(\mathbf{u}) = \mathbf{y} = \left( -\frac{1}{\beta} \ln(\mathbf{u}) \right)^{\frac{1}{\alpha}}.$$

# Loi de Cauchy

- Distribution de cauchy :  $\mathcal{C}(0, 1)$ ,

$$F(x) = \frac{1}{\pi} \arctan(x) + \frac{1}{2} \quad \text{and} \quad \mathbf{F_X^{-1}(u) = \tan(\pi(u - 1/2))}$$

Malheureusement, pour de nombreuses fonctions de distribution, nous ne disposons pas d'une expression facile utiliser pour l'inverse de F.



# Sommaire.


- 1 Méthode d'inversion
  - Applications
- 2 Simulation de lois à densité par la méthode du rejet
- 3 Cas particulier : la loi normale
  - Méthode inverse
  - Théorème Central Limite
  - Méthode de Box et Muller
  - Méthode du rejet
- 4 Cas particulier des lois discrètes

# Principe

- La méthode de rejet peut s'utiliser pour la génération de n'importe quel type de variable aléatoire.
- Elle consiste à générer des données suivant une distribution de fonction de densité proche de celle désirée et ensuite d'éliminer une certaine proportion de ces données de manière à se ramener à des données qui suivent la distribution attendue.
- Soit  $f(x)$  la densité de la V.A. à générer. On suppose que l'on sait simuler un vecteur aléatoire  $X$  de densité  $g$  et trouver une constante  $c$  ( $c \geq 1$ ) telle que  $f(x) \leq c g(x)$  pour toute valeur de  $X$ .
- On suppose que  $g(X)$  est telle que la fonction de répartition associée  $G(x)$  est analytiquement continue ainsi que son inverse  $G^{-1}(x)$ .

# Algorithme

- 1 Générer  $U_1$  de distribution  $\mathcal{U}[0, 1]$ ,
- 2 Calculer  $X = G^{-1}(U_1)$
- 3 Générer  $U_2$  de distribution  $\mathcal{U}[0, 1]$ ,
- 4 si  $c g(X) U_2 \leq f(X)$  alors on garde  $X$  comme donnée générée sinon on la "jette" et on recommence l'étape 1.



Sur la figure, on tire tout d'abord un  $X$  de distribution  $g(x)$ . On tire ensuite une variable uniforme  $U_2$  entre 0 et 1 qui va permettre de décider si on garde le  $x$  tiré. La probabilité de le garder dépend de la distance entre  $f(x)$  et  $c g(x)$  au point  $X$ . Plus la distance est grande, plus la probabilité de rejeter la donnée est grande. En fait tous les points tirés tels que  $c g(X) U_2 \geq f(X)$  sont rejetés, ce qui équivaut à corriger l'erreur d'approximation de  $f(x)$  par  $c g(x)$ .

**Probabilité d'acceptation :**

$$\begin{aligned}
 P[X\text{accepté}] &= P\left[U \leq \frac{f(X)}{c g(X)}\right] = E\left[\mathbf{I}_{\{U \leq \frac{f(X)}{c g(X)}\}}\right] \\
 &= E\left[E\left[\mathbf{I}_{\{U \leq \frac{f(X)}{c g(X)}\}}\right] | \mathbf{X}\right] \\
 &= E\left[\frac{f(X)}{c g(X)}\right] \\
 &= \int \frac{f(x)}{c g(x)} g(x) dx = \frac{1}{c}.
 \end{aligned}$$

**Loi de  $X$  :**

$$\begin{aligned}
 P[X < x | X\text{accepté}] &= \frac{P[X < x, X\text{accepté}]}{1/c} \\
 &= c P\left[X < x, U < \frac{f(X)}{c g(X)}\right] \\
 &= c E\left[\mathbf{I}_{\{X < x, U \leq \frac{f(X)}{c g(X)}\}}\right] \\
 &= c E\left[E\left[\mathbf{I}_{\{X < x, U \leq \frac{f(X)}{c g(X)}\}}\right] | \mathbf{X}\right] \\
 &= c E\left[I_{\{X < x\}} \frac{f(X)}{c g(X)}\right]
 \end{aligned}$$

# Sommaire.

- 1 Méthode d'inversion
  - Applications
- 2 Simulation de lois à densité par la méthode du rejet
- 3 Cas particulier : la loi normale**
  - Méthode inverse
  - Théorème Central Limite
  - Méthode de Box et Muller
  - Méthode du rejet
- 4 Cas particulier des lois discrètes

# Rappel : Distribution normale

La fonction densité de probabilité d'une distribution normale est :

$$f(x \mid \mu, \sigma^2) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \mathbf{1}_{[-\infty, +\infty]}(x)$$

- $\mu$  Espérance mathématique de la distribution (médiane et mode),
- $\sigma^2$  variance,  $\sigma$  écart-type.

La fonction cumulative (répartition) (CDF) de la distribution normale standard  $F(x)$  est :

$$F(x) = \frac{1}{\sigma\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{(t-\mu)^2}{2\sigma^2}} dt.$$

Cas particulier de la loi centrée réduite  $\mu = 0$  and  $\sigma = 1$  de PDF :

$$\varphi(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}x^2}$$

La fonction cumulative CDF de la loi normale, notée généralement  $\Phi$  est l'intégrale :

$$\Phi(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-t^2/2} dt.$$

# Fonction cumulative (CDF)

En statistique, on utilise souvent la fonction d'erreur, ou  $\text{erf}(x)$ , définie comme la probabilité qu'une variable aléatoire à distribution normale de moyenne 0 et de variance 1/2 se situant dans l'intervalle  $[-x, x]$ ; telle que

$$\text{erf}(x) = \frac{1}{\sqrt{\pi}} \int_{-x}^x e^{-t^2} dt$$

Les deux fonctions  $\phi$  et  $\text{erf}$  sont étroitement liées, à savoir

$$\Phi(x) = \frac{1}{2} \left[ 1 + \text{erf} \left( \frac{x}{\sqrt{2}} \right) \right]$$

Pour une distribution normale générique  $f$  avec une moyenne  $\mu$  et un écart-type  $\sigma$ , la fonction de distribution cumulée est la suivante


$$F(x) = \Phi \left( \frac{x - \mu}{\sigma} \right) = \frac{1}{2} \left[ 1 + \text{erf} \left( \frac{x - \mu}{\sigma \sqrt{2}} \right) \right]$$

# Méthode inverse


Hypothèse : on dispose d'un générateur de nombres aléatoires dans l'intervalle  $[0, 1]$ .

Remarque : La fonction de répartition de la variable qui utilise la loi normale  $\mathcal{N}(0, 1)$  peut se calculer avec la fonction **erf** sa fonction inverse avec  $\text{erf}^{-1}$  :

$$\Phi(x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-t^2/2} dt = \frac{1}{2} \left( 1 + \text{erf}\left(\frac{x}{\sqrt{2}}\right) \right) \quad \blacksquare^{-1}(u) = y = \sqrt{2} \text{erf}^{-1}(2u - 1).$$



Fonction erreur



Fonction erreur réciproque (source : wikipedia)



# Théorème Central Limite

Une application immédiate du théorème central limite donne une méthode très simple de génération de variables aléatoires normales.

- On sait que si  $X_1, X_2, \dots, X_n$  sont  $n$  variables aléatoires i.i.d. d'espérance  $\mu$  et de variance  $\sigma^2$ , en notant  $S$  leur somme, on a :

$$\frac{S - n\mu}{\sqrt{n}\sigma} \xrightarrow{(loi)} \mathcal{N}(0, 1).$$

La variable somme centrée réduite tend vers une loi normale centrée réduite lorsque  $n \rightarrow \infty$ . En particulier si les variables  $X_i$  ont une loi uniforme, on a vu que l'on avait  $E(X_i) = \mu = 1/2$  et  $\sigma_{X_i} = 1/\sqrt{12}$ .

- Partant de  $n$  variables aléatoires  $X_i$  de loi uniforme  $\mathcal{U}_{[0, 1]}$ , on peut générer une variable aléatoire  $Y$  ayant une loi normale de valeur moyenne  $\bar{Y}$  et d'écart-type  $\sigma_Y$  par la relation :

$$Y = \frac{\sum_{i=1}^n (X_i) - n/2}{\sqrt{n/12}}$$


Pratiquement, on simule 12 variables aléatoires indépendantes uniformes sur  $[0, 1]$  et on en fait la somme. La variance de cette somme vaut 1 et il faut ensuite la centrer en lui retranchant son espérance, c'est à dire 6 :

$$X = \sum_{i=1}^{12} X_i - 6.$$

La loi de cette variable est très proche de la loi normale  $\mathcal{N}(0, 1)$ .

Application :

!!!! cette méthode est une approximation d'autant plus mauvaise qu'on s'éloigne de la moyenne. Multiplier le nombre de nombres à sommer améliore la qualité de l'approximation, mais naturellement au détriment de la vitesse. Le choix de 12 nombres n'est, en fait, qu'un joli compromis.



# Méthode de Box et Muller

- 2n-échantillon de la loi  $\mathcal{N}(0, 1)$ , à partir d'un générateur de la loi uniforme. Si  $U_1$  et  $U_2$  indépendantes, de loi uniforme sur  $]0, 1[$ , le couple

$$Y_0 = \sqrt{-2 \ln U_1} \cos(2\pi U_2) ; Y_1 = \sqrt{-2 \ln U_1} \sin(2\pi U_2).$$

est formé de variables gaussiennes indépendantes centrées de variance 1.

La simulation de deux variables indépendantes de loi uniforme conduit à la simulation de deux variables aléatoires gaussiennes standard indépendantes.

- Pour simuler une V. A. de moyenne  $\mu$  et de variance  $\sigma^2$ , on pose

$$X = \mu + \sigma Y$$

où  $Y$  suit une loi normale centrée réduite.

- Preuve

A partir des variables aléatoires  $Y_1$  et  $Y_2$ , les quantités  $y_1, y_2$  et  $x_1, x_2$  s'écrivent indifféremment

$$\begin{cases} y_1 &= (-2 \ln x_1)^{\frac{1}{2}} \cos(2\pi x_2) \\ y_2 &= (-2 \ln x_1)^{\frac{1}{2}} \sin(2\pi x_2) \end{cases} \quad \begin{cases} x_1 &= \exp(-\frac{1}{2} (y_1^2 + y_2^2)) \\ x_2 &= \frac{1}{2\pi} \arctan\left(\frac{y_2}{y_1}\right) \end{cases}$$

Changement de variables  $\Rightarrow$  calcul du Jacobien :

$$\iint_V g(x_1, x_2) dx_1 dx_2 = \iint_U g(F(y_1, y_2)) |\det J_F(y_1, y_2)| dy_1 dy_2$$

on montre que

$$J(y_1, y_2) = \left| \frac{\partial(x_1, x_2)}{\partial(y_1, y_2)} \right| = \left| \begin{array}{cc} \frac{\partial x_1}{\partial y_1} & \frac{\partial x_1}{\partial y_2} \\ \frac{\partial x_2}{\partial y_1} & \frac{\partial x_2}{\partial y_2} \end{array} \right| \left( = -\left[ \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}y_1^2} \right] \left[ \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}y_2^2} \right] \right).$$

$$J(y_1, y_2) = \left| \begin{array}{cc} -y_1 \exp(-\frac{1}{2}(y_1^2 + y_2^2)) & -y_2 \exp(-\frac{1}{2}(y_1^2 + y_2^2)) \\ -\frac{1}{2\pi} \frac{y_2}{y_1^2} \frac{y_1^2}{y_1^2 + y_2^2} & \frac{1}{2\pi} \frac{1}{y_1} \frac{y_1^2}{y_1^2 + y_2^2} \end{array} \right|$$

$$J(y_1, y_2) = -\frac{1}{2\pi} \exp(-\frac{1}{2}(y_1^2 + y_2^2)) \frac{y_1^2}{y_1^2 + y_2^2} - \left(\frac{1}{2\pi}\right) \exp(-\frac{1}{2}(y_1^2 + y_2^2)) (y_2 \frac{y_2}{y_1^2}) \frac{y_1^2}{y_1^2 + y_2^2}$$

$$\begin{aligned} J(y_1, y_2) &= -\frac{1}{2\pi} \exp\left(-\frac{1}{2}(y_1^2 + y_2^2)\right) \left[ \frac{y_1^2}{y_1^2 + y_2^2} + \frac{y_2^2}{y_1^2 + y_2^2} \right] \\ &= -\frac{1}{2\pi} \exp\left(-\frac{1}{2}(y_1^2 + y_2^2)\right) \left[ \frac{y_1^2 + y_2^2}{y_1^2 + y_2^2} \right] \\ &= -\frac{1}{2\pi} \exp\left(-\frac{1}{2}(y_1^2 + y_2^2)\right) \end{aligned}$$

On vérifie alors que chaque variable  $y$  (indépendante) est distribuée suivant une loi normale.

# Méthode polaire de Marsaglia

Pour éviter d'utiliser les fonctions trigonométriques des transformées de Box Muller, considérons les variables aléatoires,  $W_1, W_2$  qui sont uniformément distribuées sur  $[-1, 1]$  telles que  $W_1^2 + W_2^2 < 1$  puissent être générées de la façon suivante

$$W_1 = 2U_1 - 1, \quad W_2 = 2U_2 - 1 \text{ where } 0 \leq W_1^2 + W_2^2 < 1$$

On substitue

$$\cos(2\pi U_1) \text{ with } \frac{W_1}{\sqrt{W_1^2 + W_2^2}}$$

$$\sin(2\pi U_1) \text{ with } \frac{W_2}{\sqrt{W_1^2 + W_2^2}}$$

En plus,  $W_1^2 + W_2^2$  est uniformément distribué sur  $[0, 1)$ ,  $-2\ln(U_2)$  est remplacé par  $\sqrt{-2\ln(W_1^2 + W_2^2)}$ .

Alors,  $X$  and  $Y$  sont générées par :

$$X = \sqrt{-2\ln(W_1^2 + W_2^2)} \frac{W_1}{\sqrt{W_1^2 + W_2^2}}$$

$$Y = \sqrt{-2\ln(W_1^2 + W_2^2)} \frac{W_2}{\sqrt{W_1^2 + W_2^2}}$$

# Méthode du rejet



Exemples :

- Enveloppe de Cauchy

$$\forall x \in \mathbb{R}, \frac{1}{\sqrt{2\pi}} e^{\frac{-x^2}{2}} \leq \sqrt{\frac{2\pi}{e}} \frac{1}{\pi} \frac{1}{1+x^2}.$$

- Enveloppe de Laplace

$$\forall x \in \mathbb{R}, \frac{1}{\sqrt{2\pi}} e^{\frac{-x^2}{2}} \leq 2 \sqrt{\frac{e}{2\pi}} \frac{1}{2} e^{-|x|}.$$



# Méthode du rejet

# Loi normale multidimensionnelle

Une variable aléatoire  $X$  suit une loi normale multidimensionnelle si sa densité de probabilité est :

$$f(X) = \frac{1}{(2\pi)^{n/2} |C|^{1/2}} \exp\left[-\frac{1}{2} (X - \mu)^t C^{-1} (X - \mu)\right]$$

$$\text{avec } X = \begin{pmatrix} X_1 \\ X_2 \\ \vdots \\ X_n \end{pmatrix} \quad \mu = \begin{pmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_n \end{pmatrix}$$

On pose  $C^{-1} = \Sigma$  l'inverse de la matrice de variance-covariance  
 $\Sigma$  est diagonalisable sous la forme :

$$\Sigma = U D_{\lambda} U^{-1} \quad \text{où} \quad \begin{cases} U & \text{matrice orthogonale } (U^{-1} = U') \\ D_{\lambda} & \text{matrice diagonale à termes positifs} \end{cases}$$

$$f(X) = \frac{1}{(2\pi)^{n/2} |C|^{1/2}} \exp\left[-\frac{1}{2} (X - \mu)^t U D_{\lambda} U^{-1} (X - \mu)\right].$$



On effectue le changement de variable

$$Y = U^{-1} (X - \mu)$$

$$\text{tel que } Y^t = (U^{-1} (X - \mu))^t = (X - \mu)^t (U^{-1})^t$$

$$\text{La propriété } (U^{-1})^t = U$$

est vérifiée car  $U$  est une matrice orthogonale.

$$f(Y) = \frac{1}{(2\pi)^{n/2} |C|^{1/2}} \exp\left[-\frac{1}{2} Y^t D_\lambda Y\right]$$


La loi de distribution  $f(Y)$  concerne des variables aléatoires indépendantes. On se ramène au cas monodimensionnel en simulant successivement les variables de manière indépendante.

Le processus de simulation peut se résumer en trois étapes :

- ➊ Génération de  $N$  observations  $Z$  de la variable centrée réduite  $\mathcal{N}(0, 1)$
- ➋ Le passage à la loi normale  $\mathcal{N}(0, \lambda_i)$  se fait par le calcul de  $Y = D_\lambda Z$
- ➌ Les  $N$  observations du vecteur  $X$  s'obtiennent par la résolution









$$Y = U^{-1} (X - \mu) \Rightarrow X = U Y + \mu \Rightarrow X = U D_\lambda Z + \mu.$$

# Loi Gaussienne - Tests statistiques



- Test de Student
- Test de Shapiro-Wilk
- Test de Lilliefors
- Test d'Anderson-Darling
- Test de D'Agostino
- Test de Jarque-Bera
- Test de Wilcoxon

# QQplot Interprétation



# Sommaire.

- 1 Méthode d'inversion
  - Applications
- 2 Simulation de lois à densité par la méthode du rejet
- 3 Cas particulier : la loi normale
  - Méthode inverse
  - Théorème Central Limite
  - Méthode de Box et Muller
  - Méthode du rejet
- 4 Cas particulier des lois discrètes

# Loi discrète à support fini

Soit  $X$  une V. A. discrète dont l'ensemble des valeurs possibles est fini :

$$X(\Omega) = \{x_1, \dots, x_d\}.$$

Notons  $p_1, p_2, \dots, p_d$  les probabilités associées telles que :

$$p_k := P(X = x_k), \quad s_0 := 0, \quad s_k := \sum_{i \leq k} p_i, \quad 1 \leq k \leq d.$$

Les points  $s_0, s_1, \dots, s_d$  induisent une partition de  $[0, 1]$  et si  $U$  est une variable de loi uniforme sur  $[0, 1]$ ,  $P(U \in [s_{k-1}, s_k]) = s_k - s_{k-1} = p_k$ .

On en déduit que  $Y := \sum_{k=1}^d x_k \mathbf{1}_{[s_{k-1}, s_k]}(U)$  a même loi que  $X$ .

Le principe à utiliser pour générer une instance de  $X$  est le suivant :

- 1 générer  $U$  de distribution  $\mathcal{U}([0, 1])$
- 2 donner à  $X$  la valeur  $x_j$  si

$$\sum_{i=1}^{j-1} p_i \leq U < \sum_{i=1}^j p_i.$$

Pratiquement on divise l'intervalle  $[0, 1]$  en  $d$  intervalles de longueur  $p_1, p_2, \dots, p_d$ . On regarde dans quel intervalle  $U$  tombe et on donne à  $X$  la valeur  $x_i$  associée au sous-intervalle.


# Loi de Bernoulli

On veut simuler une variable aléatoire de loi de Bernoulli de paramètre  $p$  ( $X \sim \mathcal{B}(p)$ ).

Si

$$U \sim \mathcal{U}([0, 1]) \quad X = \mathbf{1}_{\{U \leq p\}} \sim \mathcal{B}(p)$$

En effet



$$P(X = 1) = P(U \leq p) = \int_0^1 \mathbf{1}_{\{U \leq p\}} du = p$$

Application "Pile ou face" :

$$X \sim \mathcal{B}\left(\frac{1}{2}\right).$$

On tire  $U \rightarrow$  "Pile" si  $U \leq \frac{1}{2}$  ; "Face" sinon. Formellement, cette procédure s'écrit

$$\mathbf{1}_{\{U \leq 1/2\}}.$$

# Loi binomiale

Une v.a.  $X$  à valeurs entières comprises entre 1 et  $n$  suit une loi binômiale de paramètres  $n \in \mathbb{N}^*$  et  $p \in [0, 1]$  si :

$$\forall k = 1, \dots, n, \quad P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}.$$

## Proposition

Soient  $U_i, i = 1, \dots, n$  des v.a. uniformes sur  $[0, 1]$  indépendantes.

Soit l'ensemble des V.A. de Bernoulli  $\mathbf{1}_{\{U_i \leq p\}}$ ;  $1 \leq i \leq n$ , de paramètre  $p$  indépendantes :

$$X = \sum_{i=1}^n \mathbf{1}_{\{U_i \leq p\}} \sim \mathcal{B}(n, p)$$

alors  $X$  suit une loi binomiale de paramètres  $n$  et  $p$ .

## Méthode

Pour simuler la réalisation d'une v.a.r. de loi binomiale de paramètres  $(n, p)$ , on peut partir de l'observation que si  $U$  suit une loi uniforme sur  $[0, 1]$ , alors la v.a.r.  $Y = \mathbf{1}_{\{U \leq p\}}$  suit une loi de Bernoulli de paramètre  $p$ . Par conséquent, si  $(U_1, \dots, U_n)$  est un échantillon de la loi uniforme sur  $[0, 1]$ , alors la v.a.r.  $X = \sum_{i=1}^n \mathbf{1}_{U_i \leq p}$  est une somme de  $n$  variables de Bernoulli de même paramètre  $p$ ;  $X$  suit la loi binomiale de paramètres  $(n, p)$ .

# Loi géométrique

Une v.a.  $X$  à valeurs entières strictement positives suit une loi géométrique de paramètre  $p \in ]0, 1[$  si :

$$\forall k \geq 1, \quad P(X = k) = p(1 - p)^{k-1}$$

avec

$$① \quad E(X) = \frac{1}{p}, \quad \text{Var}(X) = \frac{1-p}{p^2}$$

$$② \quad P(X \leq k) = (1 - p)^{k-1}.$$

C'est la loi du temps d'attente d'un premier succès dans une suite d'épreuves répétées indépendantes ayant chacune même probabilité de succès  $p$ . Par conséquent si  $(U_i)_{i \geq 1}$  est une suite i.i.d. de variables suivant la loi uniforme sur  $[0, 1]$ , la V. A.

$$N := \min\{k \in \mathbb{N}^*; U_k \leq p\}$$

suit la loi géométrique de paramètre  $p$ .

( $k$  : 1er essai partir duquel on a  $U_k \leq p$ )

L'algorithme correspondant consiste donc à générer une v.a.  $U_k$  de loi uniforme tant que la valeur obtenue est supérieure ou égale à  $p$  et à s'arrêter à la première valeur de  $U_k$  strictement inférieure à  $p$  en retournant son indice.

**Défaut** : le nombre moyen de variables uniformes utilisées égal à  $E[N] = 1/p$  est grand pour des valeurs de  $p$  petites.



# Loi de Poisson

Une v.a.  $X$  à valeurs entières positives suit une loi de Poisson de paramètre  $\lambda > 0$  si :

$$\forall k \geq 0; \quad P(X = k) = e^{-\lambda} \frac{\lambda^k}{k!}$$

## Proposition :

Soit  $(E_i)_{i \geq 1}$  une suite de v.a. i.i.d. exponentielles de paramètre  $\lambda$ .

Notons  $S_1 := E_1$  et pour  $n \geq 2$ ,  $S_n := E_1 + \dots + E_n$ . On a alors

$$\forall n \geq 1, \quad P(S_n \leq 1 < S_{n+1}) = e^{-\lambda} \frac{\lambda^n}{n!}.$$

## Méthode :

La variable aléatoire

$$Y := \sum_{k=1}^{+\infty} k \mathbf{1}_{\{S_k \leq 1 < S_{k+1}\}} = \mathbf{1}_{S_1 \leq 1 < S_2} + 2 \times \mathbf{1}_{S_2 \leq 1 < S_3} + \dots + n \times \mathbf{1}_{S_n \leq 1 < S_{n+1}} + \dots$$

suit la loi de Poisson de paramètre  $\lambda$ . Pour déduire de cette formule un algorithme effectif, on simule les  $E_i$  en posant,

$$E_i = -\lambda^{-1} \ln U_i,$$

# Loi de Poisson

Les  $U_i$  étant i.i.d. de loi uniforme sur  $\mathcal{U}_{[0,1]}$ , on dispose alors des équivalences

$$S_k \leq 1 < S_{k+1} \iff \frac{-1}{\lambda} \sum_{i=1}^k \ln U_i \leq 1 < \frac{-1}{\lambda} \sum_{i=1}^{k+1} \ln U_i$$

$$\iff \prod_{i=1}^{k+1} U_i < e^{-\lambda} \leq \prod_{i=1}^k U_i$$

Algorithme :

- 1 On génère l'une après l'autre les variables  $U_i$  et on compare leur produit à  $e^{-\lambda}$ , en s'arrêtant lorsque la relation précédente est vérifiée.
- 2 On attribue alors à  $Y$  la valeur correspondante de  $k$ .